

เปลี่ยนกลิ่นให้เป็นข้อมูล

E-Nose Odor Analysis — ระบบเฝ้าระวังและพยากรณ์กลิ่นจากสถานีตรวจวัด

Data Science Process · 6 ขั้นตอน (CRISP-DM)

ข้อมูลจริง MUI-NOSE · ~91 วัน · 130,343 แถว · บันทึกทุก 1 นาที

PROBLEM & GOALS

ปัญหาหน้างาน และเป้าหมาย

บริบท

- โรงงาน/โรงบำบัดน้ำเสียติดตั้งสถานีตรวจวัดกลิ่นต่อเนื่อง
- ชุมชนรอบข้างร้องเรียนเรื่องกลิ่นบ่อยขึ้น ต้องการหลักฐานและการตัดสินใจที่เร็วขึ้น

เป้าหมาย 3 ข้อ ที่ส่งมอบได้จริง

1 Soft-sensor

ประเมินความเข้มข้น D/T
จาก Sensor 8 ตัว + สภาพอากาศ

2 Forecast

พยากรณ์ D/T ล่วงหน้า
เพื่อเตือนชุมชน/หน้างาน

3 Anomaly & Alert

ตรวจจับเหตุการณ์ผิดปกติ
+ เกณฑ์เตือนจากข้อมูลจริง

ข้อมูล และการทำความสะอาด


- ▶ ข้อมูลดิบ 130,343 แถว
- ▶ ตัด marker 'hackathon#2' -1 แถว (ไม่ใช่ข้อมูลจริง)
- ▶ ตัดแถว Sensor ว่างทุกตัว -421 แถว (เครื่อง offline)
- ▶ ค่าหลุดสเปก → แทนด้วย NaN เก็บค่า D/T ที่ดีไว้ ไม่ตัดทิ้งแถว
- ▶ ข้อมูลพร้อมใช้ 129,921 แถว (99.7%)

จุดสำคัญ: ค่า D/T สูงสุด 4 ค่า (รวม 15.29) อยู่ในแถวที่ pressure sensor glitch (AP=0) — การแทนด้วย NaN แทนการลบทิ้งแถว
ช่วยรักษาเหตุการณ์ก่กลืนแรงจริงไว้

KEY INSIGHT

กลิ่นแย่ลงต่อเนื่อง — ตรงกับที่ชุมชนร้องเรียน

แนวโน้มความเข้มข้น (D/T) ตามเวลา



ตัวเลขสำคัญ


- ครั้งแรก: 0.65
- ครั้งหลัง: 2.59
- ↑ เพิ่มขึ้น 4 เท่า
- 86% ของเหตุการณ์กลิ่นแรง
กระจุกใน 20% ท้าย

→ ควรเร่งตรวจหาแหล่งกำเนิด
ตั้งแต่มิถุนายน เม.ย.

WHEN

กลืนแรงช่วงไหนของวัน

ค่าเฉลี่ย D/T แยกตามชั่วโมง



ช่วงพีค

07:00 น.

mean D/T = 2.29


● ใช้จัดเวรเฝ้าระวัง/ตรวจสอบ
แหล่งกำเนิดในช่วงเช้า

ประเมิน D/T จากเซ็นเซอร์ได้แม่นยำ


เปรียบเทียบโมเดล (test ตามเวลา)

Model	MAE	RMSE	R ²
HistGB (Boosting)	0.358	0.500	0.861
Random Forest	0.413	0.557	0.828
Linear Reg.	1.397	1.639	-0.493

- โมเดลที่ดีที่สุด: HistGradientBoosting (RMSE 0.50, R² 0.86)
- Sensor 5 เป็นตัวขับเคลื่อนหลัก (r = 0.85)
- Linear Regression R² ติดลบ — extrapolate ช่วงกลืนแรงไม่ได้, โมเดลแบบ tree (HGB/RF) รับมือ distribution shift ได้ดีกว่า



พยากรณ์ล่วงหน้า: 2 ชั่วโมงคือจุดที่คุ้ม



อ่านผล

- 30-60 นาที: persistence เพียงพอ (D/T เปลี่ยนช้า)
- ตั้งแต่ ~2 ชม.: โมเดลชนะ เพราะจับแนวโน้มขาขึ้นได้

ที่ 120 นาที:

model 1.25 < persist 1.33

ดีขึ้น 5.5% → เดือนล่วงหน้า 2 ชม.

MODEL 3 — ANOMALY & ALERT

เกณฑ์เตือนจากข้อมูลจริง ใช้งานได้จริง

เกณฑ์เดิม (อิงสเปก 0-60)

High $\geq 15 \rightarrow$ เตือนติดแค่ 1 แฉว ใน 130k

ระบบแทบไม่เคยแจ้งเตือนกลั่นแฉว $\times$


เกณฑ์ใหม่ (percentile จากข้อมูลจริง)

Medium $\geq P90 = 4.05$

High $\geq P99 = 6.29$

ระดับ High ครอบคลุม $\sim 1\%$ ของเวลา $\checkmark$

= เตือนเฉพาะกลั่นแฉวจริง



ตรวจพบ 1,301 จุดเวลาผิดปกติ รวมเป็น 155 เหตุการณ์ (episode) พร้อมเวลาเริ่ม-จบ-จุดพีค ไว้ใช้ตอบข้อร้องเรียน D/T

สรุป & ข้อเสนอแนะหน้างาน

- ✓ Soft-sensor ประเมิน D/T ได้แม่นยำ (R^2 0.86) — ตรวจสอบ/เติมค่าที่หายได้
- ✓ Forecast 2 ชั่วโมง ดีกว่า baseline — เตือนชุมชน/หน่วยงานล่วงหน้า
- ✓ เกณฑ์เตือนใหม่ (Medium P90 / High P99) ทำให้ระบบแจ้งเตือนใช้งานได้จริง
- ✓ Insight: กลิ่นเพิ่มขึ้น 4 เท่าในครึ่งหลัง — เร่งตรวจแหล่งกำเนิดตั้งแต่กลางเม.ย.

ข้อจำกัด

ข้อมูลเพียง 3 เดือน · label กลิ่นมีแค่ 'Ambient' (ยังจำแนกชนิดกลิ่นไม่ได้) · ควร retrain เป็นระยะเมื่อมีข้อมูลใหม่